

Data Encoding - TryHackMe

Objectif

Comprendre comment les systèmes informatiques encodent les caractères pour stocker et afficher du texte, de l'ASCII historique jusqu'à la norme universelle Unicode.

Reconnaissance / Théorie

- **ASCII (American Standard Code for Information Interchange)** : Un standard créé en 1963 utilisant 7 bits pour représenter 128 caractères, incluant les lettres anglaises, les chiffres, la ponctuation et les caractères de contrôle.
- **Limites et chaos régional** : Pour intégrer les spécificités des langues européennes, des normes étendues comme la série ISO/IEC 8859 (Latin-1, Latin-2) ont ajouté un huitième bit. Cependant, ouvrir un fichier avec un encodage différent de celui utilisé lors de sa sauvegarde provoque des erreurs d'affichage et l'altération des caractères.
- **Unicode** : Un standard de codage universel qui attribue un numéro unique (code point) à chaque caractère ou symbole de toutes les langues modernes et historiques, y compris les emojis (par exemple, U+0041 pour la lettre latine "A" ou U+1F525 pour l'emoji feu).

Exploitation / Résolution

1. J'ai analysé la conversion directe de chaînes de texte en hexadécimal et binaire. Par exemple, la chaîne "TryHackMe" suivie d'un saut de ligne se traduit au niveau des octets par `54 72 79 48 61 63 6b 4d 65 0a` en hexadécimal.
2. J'ai exploré les différentes implémentations de la norme Unicode pour le stockage physique :
 - **UTF-8** : Encodage dynamique utilisant de 1 à 4 octets par caractère. Il est rétrocompatible avec l'ASCII (1 octet) et très courant sur le web moderne pour économiser de l'espace.
 - **UTF-16** : Utilise 2 ou 4 octets par caractère, regroupant souvent les écritures courantes sur 2 octets et les symboles complexes comme les emojis sur 4 octets.
 - **UTF-32** : Le format le plus simple mais le plus gourmand en espace, allouant systématiquement 4 octets exacts pour chaque point de code Unicode.

Résultat

✓ Maîtrise des standards d'encodage et de leur impact sur la manipulation des données. Comprendre ces encodages est indispensable en cybersécurité pour l'analyse forensique, l'ingénierie inverse et la détection d'obfuscation, car une mauvaise interprétation de l'encodage (par exemple, confondre UTF-8 et UTF-16) peut rendre l'analyse d'un payload ou d'un fichier log totalement illisible.



Outils utilisés

- **Standards de base** : ASCII, ISO/IEC 8859
- **Standards universels** : Unicode (Code points U+XXXX)
- **Formats d'implémentation** : UTF-8, UTF-16, UTF-32